Análise do conjunto de Dados Boston Housing

- > library(dplyr)
- > library(ggcorrplot)
- > ### Reading the Boston Housing data ###
- > Boston = read.csv("http://stat.wharton.upenn.edu/~khyuns/stat431/BostonHousing.txt")
- > attach(Boston)
- > head(Boston)

Estes dados estão contidos também no pacote MASS. Eles podem ser lidos da seguinte forma:

- > require(MASS)
- > data(Boston)
- > # Digitando
- > help(Boston)
- > # vai mostrar a descrição dos dados
- > head(Boston)

	crim	zn <dbl></dbl>	indus <db ></db >	chas <int></int>	nox <db ></db >	rm <db ></db >	age <dbl></dbl>	dis <dbl></dbl>	rad <int></int>
	<dbl> <</dbl>								
1	0.00632	18	2.31	0	0.538	6.575	65.2	4.0900	1
2	0.02731	0	7.07	0	0.469	6.421	78.9	4.9671	2
3	0.02729	0	7.07	0	0.469	7.185	61.1	4.9671	2
4	0.03237	0	2.18	0	0.458	6.998	45.8	6.0622	3
5	0.06905	0	2.18	0	0.458	7.147	54.2	6.0622	3
6	0.02985	0	2.18	0	0.458	6.430	58.7	6.0622	3

Descrição dos Dados

- 1. CRIM: per capita crime rate by town
- 2. ZN: proportion of residential land zoned for lots over 25,000 sq.ft.
- 3. INDUS: proportion of non-retail business acres per town
- 4. CHAS: Charles River dummy variable (= 1 if tract bounds river; 0 otherwise)
- 5. NOX: nitric oxides concentration (parts per 10 million)
- 6. RM: average number of rooms per dwelling
- 7. AGE: proportion of owner-occupied units built prior to 1940
- 8. DIS: weighted distances to five Boston employment centres
- 9. RAD: index of accessibility to radial highways
- 10. TAX: full-value property-tax rate per \$10,000
- 11. PTRATIO: pupil-teacher ratio by town
- 12. B: 1000(Bk 0.63)² where Bk is the proportion of blacks by town
- 13. LSTAT: % lower status of the population
- 14. MEDV: Median value of owner-occupied homes in \$1000's

Sugestão de Análise

Exploração dos Dados

- Sumários estatísticos (summary, dim, cor, etc)
- · Gráficos exploratórios

Ajuste Modelo Linear


• Crie dois subconjuntos dos dados: train e test de modo a poder avaliar a capacidade preditora de seu modelo.


```
> set.seed(1234)
> train <- sample_frac(Boston, 0.7)
> sid <- as.numeric(rownames(train)) # because rownames() returns character
> test <- Boston[-sid, ]</pre>
```

```
> str(train)
'data.frame':
              354 obs. of 14 variables:
         : num 0.015 0.0396 67.9208 0.1487 0.1057 ...
 $ crim
 $ zn
         : num 90000000000...
 $ indus : num 1.21 5.19 18.1 8.56 27.74 ...
        : int 1000000000...
 $ chas
        : num 0.401 0.515 0.693 0.52 0.609 0.52 0.7 0.624 0.718 0.693 ...
 $ nox
 $ rm
        : num 7.92 6.04 5.68 6.73 5.98 ...
        : num 24.8 34.5 100 79.9 98.8 54.4 97 97.9 95.3 77.8 ...
 $ age
 $ dis
      : num 5.88 5.99 1.43 2.78 1.87 ...
        : int 1 5 24 5 4 5 24 4 24 24 ...
 $ rad
        : num 198 224 666 384 711 384 666 437 666 666 ...
 $ tax
 $ ptratio: num 13.6 20.2 20.2 20.9 20.1 20.9 20.2 21.2 20.2 20.2 ...
 $ black
        : num 396 397 385 395 390 ...
 $ 1stat
        : num 3.16 8.01 22.98 9.42 18.07 ...
         : num 50 21.1 5 27.5 13.6 21.7 9.7 23 14.2 6.3 ...
 $ medv
> str(test)
'data.frame':
              152 obs. of 14 variables:
         : num 0.043 0.107 8.983 3.85 5.202 ...
 $ crim
        : num 80 80 0 0 0 0 0 0 0 ...
 $ zn
 : int 0011100001 ...
 $ chas
        : num 0.413 0.413 0.77 0.77 0.77 0.77 0.77 0.77 0.77 ...
 $ nox
        : num 5.66 5.94 6.21 6.39 6.13 ...
 $ rm
      : num 21.9 19.5 97.4 91 83.4 81.3 88 91.1 96.2 89 ...
 $ age
 $ dis
        : num 10.59 10.59 2.12 2.51 2.72 ...
        : int 4 4 24 24 24 24 24 24 24 24 ...
 $ rad
        : num 334 334 666 666 666 666 666 666 666 ...
 $ tax
 $ black : num 383 376 378 391 395 ...
 $ lstat : num 8.05 5.57 17.6 13.27 11.48 ...
         : num 18.2 20.6 17.8 21.7 22.7 22.6 25 19.9 20.8 16.8 ...
> # write.csv(test,file='datasets/boston_test_prof.csv',row.names
> # = FALSE, quote = FALSE)
> # write.csv(train,file='datasets/boston_train_prof.csv',row.names=FALSE,quote=FALSE)
```

Inspecionando correlações entre as variáveis

```
> library(GGally)
> ggpairs(Boston)
```





Percebemos correlações fortes entre variáveis explicativas; isso não é bom e vai atrapalhar o modelo.

Ajuste de Modelo Linear (1m) — queremos prever o valor mediano das residências MEDV.

- Análise do ajuste:
 - summary(modelo)
 - gráficos diagnósticos

Seleção de Modelos (Variáveis Explicativas)

Seleção de Modelos (variáveis explicativas)

```
> model.1 <- lm(medv ~ ., data = train)</pre>
> summary(model.1)
Call:
lm(formula = medv ~ ., data = train)
Residuals:
    Min
              1Q
                   Median
                                 3Q
                                        Max
-16.2210 -2.5130 -0.7122
                            1.8295
                                   26.9382
Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept)
            26.399485
                        6.347070
                                   4.159 4.05e-05 ***
crim
             -0.111639
                        0.035323 -3.160 0.001717 **
             0.044388
                        0.015841
                                  2.802 0.005367 **
zn
             -0.008549
                        0.071304 -0.120 0.904641
indus
chas
             2.793031
                        0.972463
                                  2.872 0.004333 **
            -17.494132
                        4.314041 -4.055 6.22e-05 ***
nox
             4.907947
                        0.542364
                                  9.049 < 2e-16 ***
rm
             -0.016715
                        0.015386 -1.086 0.278074
age
             -1.441577
                        0.229553 -6.280 1.03e-09 ***
dis
             0.254051
rad
                        0.075422 3.368 0.000843 ***
                                  -2.678 0.007765 **
tax
             -0.011540
                        0.004309
             -0.838551
                        0.154130 -5.441 1.02e-07 ***
ptratio
                                   3.000 0.002896 **
black
             0.009602
                        0.003200
                        0.062357 -5.474 8.55e-08 ***
1stat
            -0.341352
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
Residual standard error: 4.656 on 340 degrees of freedom
Multiple R-squared: 0.7508,
                               Adjusted R-squared: 0.7413
F-statistic: 78.79 on 13 and 340 DF, p-value: < 2.2e-16
```

VIF

Para uma dada variável preditora (p), podemos aferir a multicolineraridade calculando um índice chamado "fator de inflação de variância" (VIF), que mede o quanto a variância do coeficiente de regressão é inflacionado devido a multicolineraridade no modelo.

O menor valor possível de VIF é um (ausência de multicolinearidade). Como regra geral, um valor de VIF que excede 5 ou 10 indica uma quantidade problemática de multicolinearidade.

Quando temos multicolinearidade, as variáveis envolvidas devem ser removidas, já que a presença de multicolinearidade implica que a informação que esta variável provê sobre a resposta é redundante na presença das outras variáveis.

```
> car::vif(model.1)
    crim     zn    indus    chas     nox     rm     age     dis
1.770761 2.164574 3.969857 1.087845 4.259040 2.274295 3.055292 3.746143
    rad     tax    ptratio     black     lstat
7.094406 8.823177 1.807068 1.361045 3.463498
```

Inicialmente detectamos a variável tax

```
> model.2 <- update(model.1, medv ~ . - tax)</pre>
> summary(model.2)
Call:
lm(formula = medv ~ crim + zn + indus + chas + nox + rm + age +
   dis + rad + ptratio + black + lstat, data = train)
Residuals:
   Min
           1Q Median
                         3Q
                               Max
-16.6866 -2.7722 -0.6172 1.8859 26.8975
Coefficients:
          Estimate Std. Error t value Pr(>|t|)
                           3.871 0.00013 ***
(Intercept) 24.657384
                  6.370527
         crim
          zn
         indus
chas
          3.065232 0.975849 3.141 0.00183 **
nox
         -18.168004 4.345495 -4.181 3.70e-05 ***
          4.991936 0.546335 9.137 < 2e-16 ***
rm
         -0.017086 0.015524 -1.101 0.27184
age
dis
         rad
         ptratio
black
          0.009902 0.003227 3.068 0.00233 **
                 0.062918 -5.412 1.17e-07 ***
lstat
         -0.340533
---
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
Residual standard error: 4.698 on 341 degrees of freedom
Multiple R-squared: 0.7455,
                       Adjusted R-squared: 0.7366
F-statistic: 83.25 on 12 and 341 DF, p-value: < 2.2e-16
```

```
> car::vif(model.2)
    crim     zn     indus     chas     nox     rm     age     dis
1.770412  2.086330  3.064516  1.075961  4.244550  2.266690  3.055045  3.745819
    rad ptratio     black     lstat
2.905852  1.793446  1.359381  3.463415
```

```
> model.3 <- update(model.2, medv ~ . - age)</pre>
> summary(model.3)
Call:
lm(formula = medv ~ crim + zn + indus + chas + nox + rm + dis +
   rad + ptratio + black + lstat, data = train)
Residuals:
   Min
            1Q Median
                          3Q
                                Max
-16.3648 -2.8158 -0.5752 1.8242 26.5875
Coefficients:
           Estimate Std. Error t value Pr(>|t|)
(Intercept) 25.203891 6.353108
                             3.967 8.86e-05 ***
crim
          0.038708 0.015546 2.490 0.01325 *
zn
indus
          -0.101751 0.063205 -1.610 0.10835
chas
          2.998826 0.974283 3.078 0.00225 **
nox
         -19.480487 4.179960 -4.660 4.53e-06 ***
          4.874112 0.535909 9.095 < 2e-16 ***
rm
          dis
rad
          ptratio
black
          0.009622 0.003218 2.990 0.00299 **
lstat
          Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
Residual standard error: 4.7 on 342 degrees of freedom
Multiple R-squared: 0.7446, Adjusted R-squared: 0.7364
F-statistic: 90.65 on 11 and 342 DF, p-value: < 2.2e-16
> car::vif(model.3)
                 indus
                         chas
                                nox
                                         rm
                                               dis
1.770412 2.046523 3.061952 1.071848 3.924904 2.179660 3.432532 2.894475
ptratio
         black
                lstat
1.786154 1.350901 3.169559
```

Avaliando a habilidade preditora do nosso modelo

```
> fitted.values <- predict(model.3, newdata = test, type = "response")
> # fitted.values
> diferenca <- fitted.values - test$medv
> (rmse <- sqrt(mean(diferenca^2)))
[1] 6.573464</pre>
```